






Introduction

Boltzmann Machine

boltzmann machineの目的(1)




- 神経回路網を模した数理モデル
 - hopfield netなどのコネクショニストモデルの1つ
- 環境からの信号が入力素子 \mathbf{V} へ
この環境の確率構造 P を神経回路網 W へ写し取る





boltzmann machineの目的(2)



事象




事象



- 神経回路網が置かれている環境の中で事象は確率的に起こる
- 環境での確率的な構造を回路網に写し取りたい
- このとき事象は $\{0,1\}$ の2値パターンの組合せで表現される

boltzmann machineの目的(3)



KL情報量 $G = \sum_{\alpha} P(V_{\alpha}) \ln \frac{P(V_{\alpha})}{P'(V_{\alpha})}$ (8)

- KL情報量
 - 環境のもつ確率構造Pと神経回路網Wを実行したときの確率P'の近さを測る
- この値を微分して勾配法を用いることで修正する

確率構造を写し取れる仕組み

- 環境がもつ確率構造 p_{ij}
- 回路網を自由に走らせることでえられる p'_{ij}
- P と P' のKL情報量を目的関数 G とする
- 目的関数 $G(P||P')$ を結合係数 w_{ij} で微分



$$\frac{\partial G}{\partial w_{ij}} = -\frac{1}{T}(p_{ij} - p'_{ij}) \quad (9)$$

$$\Delta w_{ij} = \epsilon(p_{ij} - p'_{ij}) \quad (10)$$

- 結合係数を少しずつ修正していく

$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\boldsymbol{\mu}^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$

神経回路網の状態






$$E(\mathbf{v}, \mathbf{h}; \theta) = -\frac{1}{2}\mathbf{v}^\top \mathbf{L} \mathbf{v} - \frac{1}{2}\mathbf{h}^\top \mathbf{J} \mathbf{h} - \mathbf{v}^\top \mathbf{W} \mathbf{h}, \quad (1)$$

- 回路状態はエネルギー関数で表される

エネルギー関数



$$E = - \sum_{i < j} w_{ij} s_i s_j + \sum_i \theta_i s_i$$



- エネルギー関数
 - 重み付き総和
 - 回路W上の各素子sが同時に1になったとき減少

神経細胞の発火確率


$$\sigma(x) = 1 / (1 + \exp(-x))$$



- 非線形関数では微分できない
- 閾値関数を近似する微分可能な関数が必要

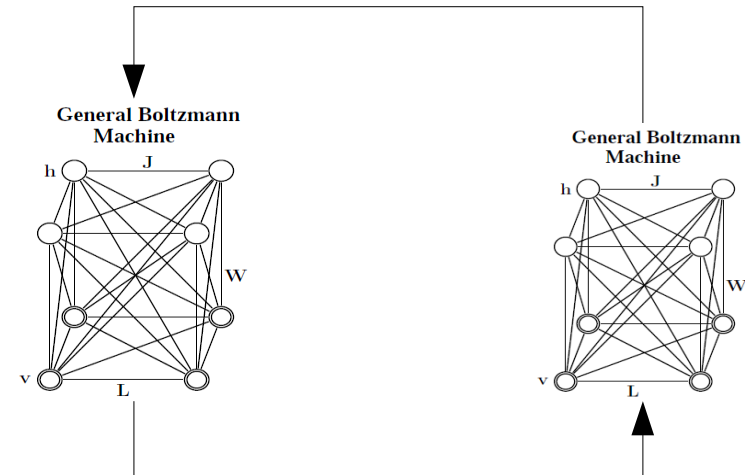

$$p(\mathbf{v}; \theta) = \frac{p^*(\mathbf{v}; \theta)}{Z(\theta)} = \frac{1}{Z(\theta)} \sum_h \exp(-E(\mathbf{v}, \mathbf{h}; \theta)),$$

$$Z(\theta) = \sum_{\mathbf{v}} \sum_{\mathbf{h}} \exp(-E(\mathbf{v}, \mathbf{h}; \theta)), \quad (3)$$



- 回路状態は状態数 2^n 個のマルコフ連鎖
- 定常分布はユニークでボルツマン分布となる

マルコフ連鎖



- 回路状態は状態数 2^n 個のマルコフ連鎖
- 定常分布はユニークに定まり, ボルツマン分布となる

神経回路網の更新則

データ依存期待値 モデル依存期待値

$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\boldsymbol{\mu}^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$

The diagram illustrates the weight update rule. It shows the current weight matrix W (red square) being updated by the difference between two expectation terms. The first term is the data-dependent expectation (blue square, labeled N), and the second term is the model-dependent expectation (green square, labeled M).

結合状態の更新則

学習係数 データ依存期待値 モデル依存期待値

$$\begin{aligned}\Delta \mathbf{W} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v}\mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v}\mathbf{h}^{\top}] \right), \\ \Delta \mathbf{L} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v}\mathbf{v}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v}\mathbf{v}^{\top}] \right), \\ \Delta \mathbf{J} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{h}\mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{h}\mathbf{h}^{\top}] \right),\end{aligned}\tag{6}$$

ここをどうやって推定するか？


Variational
approach

Stochastic
approximation
procedure



Boltzmann machineのアルゴリズム

$$W^{t+1} = W^t + \alpha_t \left(\overbrace{\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\boldsymbol{\mu}^n)^\top}^{\text{データ依存期待値}} - \overbrace{\frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top}^{\text{モデル依存期待値}} \right)$$

- 訓練データ の期待値を求める
- モデルの期待値 を求める
- 神経回路を更新



variational learning




$$\begin{aligned} \ln p(\mathbf{v}; \theta) &\geq \sum_{\mathbf{h}} q(\mathbf{h}|\mathbf{v}; \mu) \ln p(\mathbf{v}, \mathbf{h}; \theta) + \mathcal{H}(q) \quad (7) \\ &= \ln p(\mathbf{v}; \theta) - KL[q(\mathbf{h}|\mathbf{v}; \mu) || p(\mathbf{h}|\mathbf{v}; \theta)], \end{aligned}$$

- 訓練データ の対数尤度を最大化
- 近似事後確率 $q(\mathbf{h}; \mu)$ と真の事後確率 $p(\mathbf{v}; \theta)$ を間のKL情報量を最小化
- パラメータは対数尤度上での下限の勾配により更新

variational learning

General Boltzmann Machine



$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\mu^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$



mean field fixed point equation


$$\mu_j \leftarrow \sigma \left(\sum_i W_{ij} v_i + \sum_{m \neq j} J_{mj} \mu_m \right).$$

- データに依存する期待値
- 訓練データ \mathbf{v}^n から変分パラメータ μ^n を獲得

variational learning

$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\mu^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$

General Boltzmann Machine



mean field fixed point equation

$$\mu_j \leftarrow \sigma \left(\sum_i W_{ij} v_i + \sum_{m \neq j} J_{mj} \mu_m \right). \quad (8)$$

$$q(\mathbf{h}; \mu) = \prod_{j=1}^P q(h_j), \text{ with } q(h_j = 1) = \mu_j$$

- 訓練データ \mathbf{v}^n から変分パラメータ μ^n を獲得

variational learning

$$q(\mathbf{h}; \mu) = \prod_{j=1}^P q(h_j), \text{ with } q(h_i = 1) = \mu_i$$

$$\mu_j \leftarrow \sigma\left(\sum_i W_{ij} v_i + \sum_{m \neq j} J_{mj} \mu_m\right).$$

(8)

- naive mean-field approach
 - 完全に因数分解できるモデル
 - 単純な手続きで収束がはやい
 - 確率分布 $p(h)$ の近似値

結合状態の更新則

学習係数 データ依存期待値 モデル依存期待値

$$\begin{aligned}\Delta \mathbf{W} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v}\mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v}\mathbf{h}^{\top}] \right), \\ \Delta \mathbf{L} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v}\mathbf{v}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v}\mathbf{v}^{\top}] \right), \\ \Delta \mathbf{J} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{h}\mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{h}\mathbf{h}^{\top}] \right),\end{aligned}\tag{6}$$


ここをどうやって推定するか？

variational
approach


stochastic
approximation
procedure

stochastic approximation procedure

$$(\tilde{\mathbf{v}}^{t,m}, \tilde{\mathbf{h}}^{t,m}).$$



$$T_{\theta_t}(X^{t+1}; X^t)$$



- 現在の状態 $(\tilde{\mathbf{v}}^{t,m}, \tilde{\mathbf{h}}^{t,m})$ から次の状態 $(\tilde{\mathbf{v}}^{t+1,m}, \tilde{\mathbf{h}}^{t+1,m})$ を獲得

結合状態の更新則

学習係数 データ依存期待値 モデル依存期待値

$$\begin{aligned}\Delta \mathbf{W} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v} \mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v} \mathbf{h}^{\top}] \right), \\ \Delta \mathbf{L} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{v} \mathbf{v}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{v} \mathbf{v}^{\top}] \right), \\ \Delta \mathbf{J} &= \alpha \left(\mathbb{E}_{P_{\text{data}}} [\mathbf{h} \mathbf{h}^{\top}] - \mathbb{E}_{P_{\text{model}}} [\mathbf{h} \mathbf{h}^{\top}] \right),\end{aligned}\tag{6}$$

ここをどうやって推定するか？

Variational
approach

Stochastic
approximation
procedure

stochastic approximation procedure

transition operator


$$T_{\theta_t}(X^{t+1}; X^t)$$

中身は？

k-step gibbs sampling

$$p(h_j = 1 | \mathbf{v}, \mathbf{h}_{-j}) = \sigma\left(\sum_{i=1}^D W_{ij} v_i + \sum_{m=1 \setminus j}^P J_{jm} h_j\right), \quad (4)$$


$$p(v_i = 1 | \mathbf{h}, \mathbf{v}_{-i}) = \sigma\left(\sum_{j=1}^P W_{ij} h_j + \sum_{k=1 \setminus i}^D L_{ik} v_j\right), \quad (5)$$



- 可視層vと隠れ層hを交互に遷移

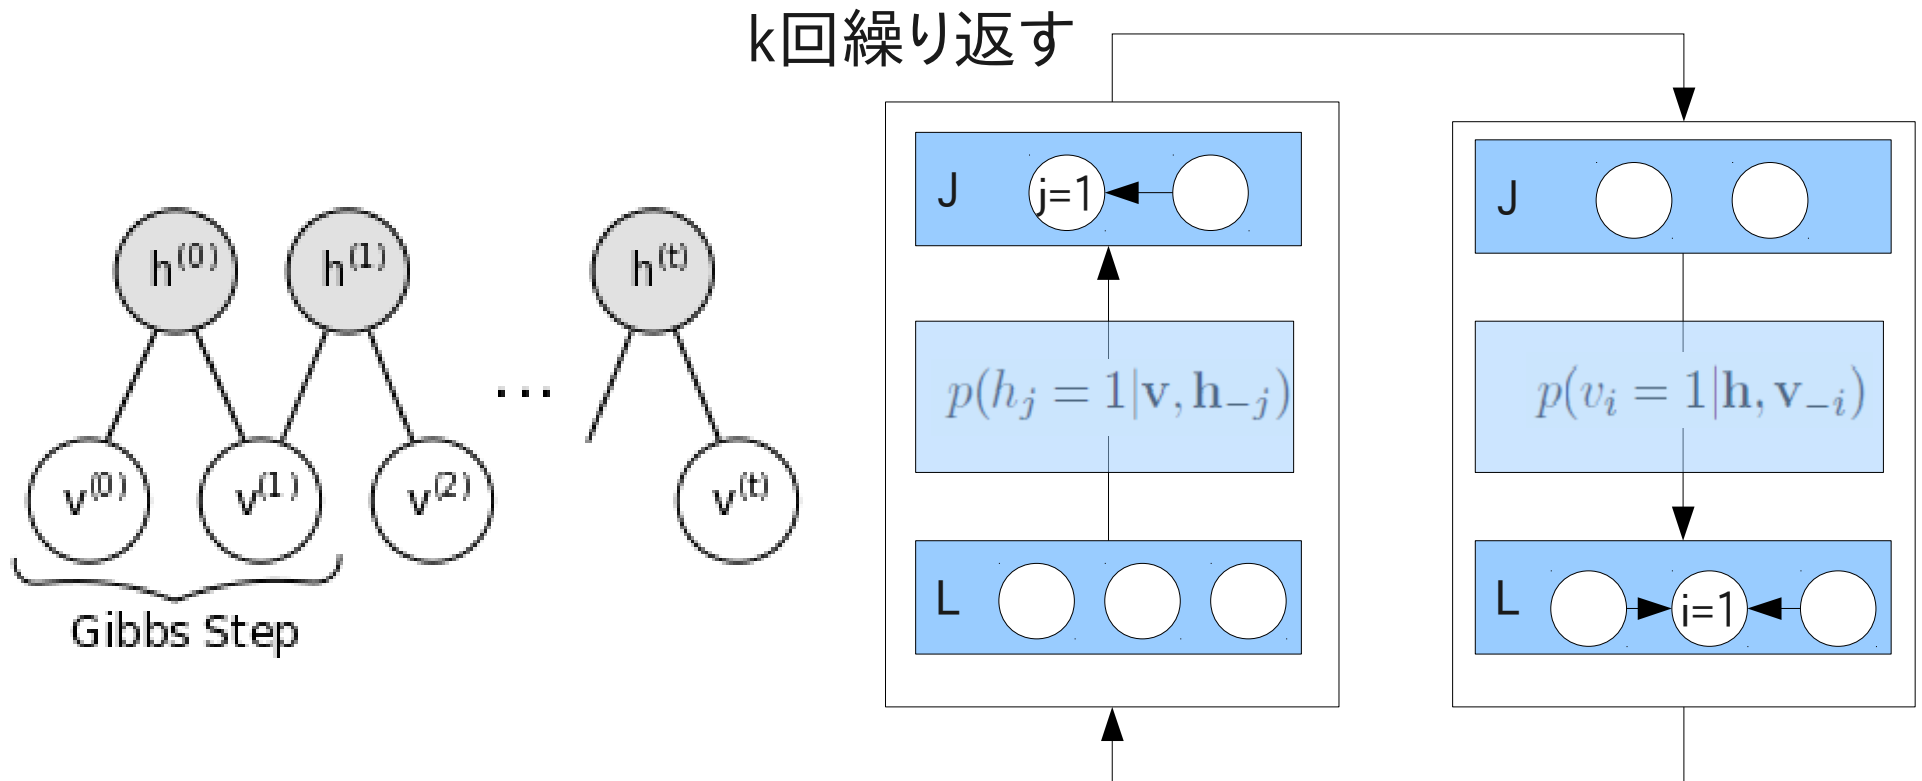
k-step gibbs sampling (全結合可視素子の場合)

$$p(x_i = 1 | x_{i-1}) = \frac{1}{1 + \exp(-u_i)}$$



- 1つの神経細胞を選択
- 確率にしたがい発火させる

k-step gibbs sampling (可視素子v, 隠れ素子hを持つとき)



- 隠れ層hの素子をランダムに1つ選択.
eq(4)の確率で発火
- 可視層vの素子をランダムに1つ選択.
eq(5)で確率で発火

$$p(h_j = 1 | \mathbf{v}, \mathbf{h}_{-j}) = \sigma \left(\sum_{i=1}^D W_{ij} v_i + \sum_{m=1 \setminus j}^P J_{jm} h_m \right), \quad (4)$$

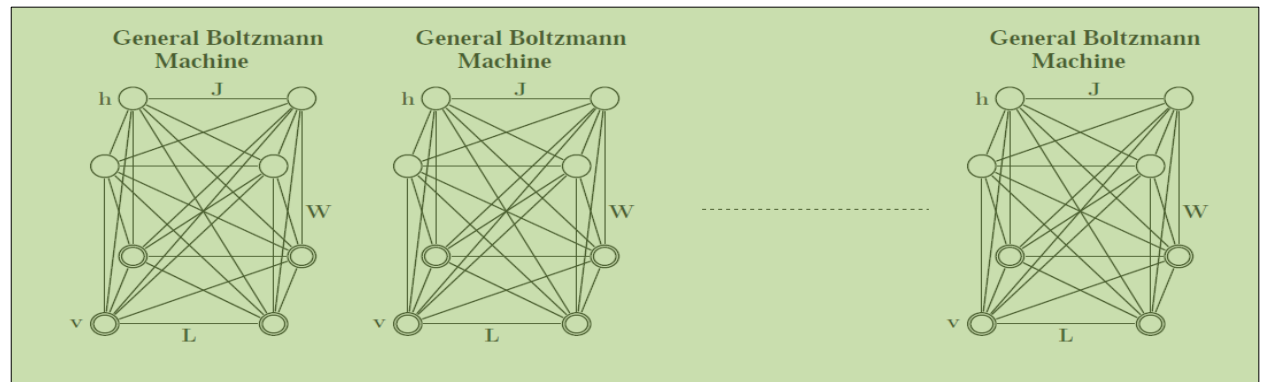
$$p(v_i = 1 | \mathbf{h}, \mathbf{v}_{-i}) = \sigma \left(\sum_{j=1}^D W_{ij} h_j + \sum_{k=1 \setminus i}^P L_{ik} v_k \right), \quad (5)$$

stochastic approximation procedure

$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\boldsymbol{\mu}^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$

M fantasy particle

$$(\tilde{\mathbf{v}}^{t,m}, \tilde{\mathbf{h}}^{t,m}).$$




- Robbins-Monro型のアルゴリズム
- モデルパラメータの期待値をとる

Robbins-Monroアルゴリズム

神経回路網の更新

General Boltzmann
Machine



$$W^{t+1} = W^t + \alpha_t \left(\frac{1}{N} \sum_{n=1}^N \mathbf{v}^n (\mu^n)^\top - \frac{1}{M} \sum_{m=1}^M \tilde{\mathbf{v}}^{t+1,m} (\tilde{\mathbf{h}}^{t+1,m})^\top \right)$$