

精読用

T1076006 塩貝亮宇

0.1 Greedy Layerwise Pretraining of DBM's

Hinton et al.(2006) は RBM の持つある層のスタックを同時に学習できる貪欲な学習アルゴリズムを紹介した.

RBM が持つスタックの学習後は, 全てのスタックは 1 つの確率モデルと見なされ, これは 'deep belief network' と呼ばれる.

驚くべきことに, このモデルは Deep Boltzmann machine ではない.

トップの 2 層は無方向グラフの RBM だが, 下層は有向グラフの生成モデルを形成している (図 2 参照).

このスタック中の最初の RBM を学習した後, 生成モデルは次式のように書くことができる.

$$p(\mathbf{v}; \theta) = \sum_{\mathbf{h}^1} p(\mathbf{h}^1; \mathbf{W}^1) p(\mathbf{v} | \mathbf{h}^1; \mathbf{W}^1), \quad (1)$$

(2)

ここで,

$$p(\mathbf{h}^1; \mathbf{W}^1) = \sum_{\mathbf{v}} p(\mathbf{h}^1, \mathbf{v}; \mathbf{W}^1) \quad (3)$$

は, 事前に暗黙的に \mathbf{h}^1 から定義されたパラメータである.

スタック中の 2 番目の RBM は $p(\mathbf{h}^1; \mathbf{W}^1)$ は

$$p(\mathbf{h}^1; \mathbf{W}^2) = \sum_{\mathbf{h}^2} p(\mathbf{h}^1, \mathbf{h}^2; \mathbf{W}^2) \quad (4)$$

に置き換える.

もし, 2 番目の RBM が正しく初期化されていれば (Hinton et al., 2006), $p(\mathbf{h}^1; \mathbf{W}^2)$ は \mathbf{h}^1 の事後確率の集合より良いモデルとなるだろう.

ここでの事後確率の集合は全ての訓練のケースは, 単純な (non-factorial, 非階乗事後) が混じった (階乗事後, factorial posterior) である.

したがって,

$$\frac{1}{N} \sum_n p(\mathbf{h}^1 | \mathbf{v}_n; \mathbf{W}^1) \quad (5)$$

(6)

2 番目の RBM は

$$p(\mathbf{h}^1; \mathbf{W}^1) \quad (7)$$

から, より良いモデルに置き換えられて,

$$p(\mathbf{h}^1; \mathbf{W}^1, \mathbf{W}^2) \quad (8)$$

(9)

は

$$\frac{1}{2} \mathbf{W}^1 \quad (10)$$

と

$$\frac{1}{2}\mathbf{W}^2 \quad (11)$$

を用いて近似できた

$$\mathbf{h}^1 \quad (12)$$

の 2 つのモデルの平均から推論される.

ボトムアップ \mathbf{W}^1 とトップダウン \mathbf{W}^2 を使うことは, \mathbf{v} に依存する \mathbf{h}^2 からの (証言, 証拠, evidence) をダブルカウントする量になるだろう.

DBM のモデルパラメータを初期化するために, RBM が持つスタックの学習による層と層の事前学習の貪欲な方法を提案するが,

トップダウンとボトムアップの影響を一体化した後にダブルカウント問題を除いた小さな変化と一緒に.

下位レベルの RBM について, 2 倍の入力と可視層から隠れ層への重みの結合を図 (2) 右に示す.

この結合したパラメータ RBM の変化は隠れと可視状態からの事後確率が次式のように定義される.

$$p(h_j^i = 1|\mathbf{v}) = \sigma(\sum_i W_{ij}^1 v_i + \sum_i W_{ij}^1 v_i), \quad (13)$$

$$p(v_i = 1|\mathbf{h}^1) = \sigma(\sum_j W_{ij}^1 h_j^1). \quad (14)$$

Contrastive divergence learning はうまく働き, そして, 変化した RBM は, その良い訓練データを再構築する.

反対に, トップレベルの RBM について私たちは隠れ素子の数を 2 倍にする.

このモデルについての条件付分布は次の形式をとる:

$$p(h_j^1 = 1|\mathbf{h}^2) = \sigma(\sum_m W_{jm}^2 h_m^2 + \sum_m W_{jm}^2 h_m^2) \quad (15)$$

$$p(h_m^2 = 1|\mathbf{h}^1) = \sigma(\sum_j W_{jm}^2 h_j^1). \quad (16)$$

これら 2 つのモジュールが 1 つのシステムとして (落ち付き, 構成する, compose) とき, 最初の隠れ層への総合的な入力 は次式の \mathbf{h}^1 からの条件付分布の半分になる.

$$p(h_j^i = 1|\mathbf{v}, \mathbf{h}^2) = \sigma(\sum_i W_{ij}^1 v_i + \sum_m W_{jm}^2 h_m^2) \quad (17)$$

$$(18)$$

\mathbf{v} と \mathbf{h}^2 についての条件付分布は式 (16),(18) に定義したままである.

(一体化させたモデル, composed model) によって定義された条件付き分布は DBM によって定義された式 (11,12,13) の条件付分布と同じものとなる.

したがって, 貪欲な事前訓練は 2 つを変更した RBM の対称な重みをもつ 1 つの無方向グラフモデルを導く-deep boltzmann machine.

2 つ以上の RBM のスタックを貪欲に事前学習させたとき, スタックの最初と最後の RBM については変更のためだけに必要となる.

中間に存在する全ての RBM は, どちら向きの重みであってもそれらを (組み立てた, compose) ときに boltzmann machine を形成する.

こうした手法による貪欲な事前訓練での DBM の重みは 2 つの役目を果たす.

まず, (経験に基づく, experimental) 結果のセクションを示し, (分別のある, 常識のある, sensible) 重みによって初期化する.

2 つ目,RBM のスタックが上向きに通る経路によって近似の影響による性能が非常にはよくなる方法が保障される.

可視素子上に与えられたデータベクトルは,

各隠れ素子層はトップダウンフィードバックの欠落について釣り合いをとるためのボトムアップ入力の (倍加,doubling) によって (活性化される,activated).

この高速な (推定,inference) の近似は平均場法として初期化され, ランダムに初期化された場合よりも高速に収束する.